

一、 名词解释：

1. 特征选择与特征提取

名词约定：

■ 特征形成（特征获取、提取）

直接观测到的或经过初步运算的特征——

■ 特征选择

从 m 个特征中选择 m_1 个， $m_1 < m$ （人

■ 特征提取（特征变换，特征压缩）

将 m 个特征变为 m_2 个新特征

2. 特征的评价准则

概念：数学上定义的用以衡量特征对分类的效果的准则，实际问题中需根据实际情况人为确定。’

误识率判据：理论上的目标，实际采用困难（密度未知，形式复杂，样本不充分， …）

可分性判据：实用的可计算的判据

3. 总类内离散度矩阵 S_w ,总类间离散度矩阵 S_b 。（写出计算公式）

类间平均距离：

$$J_D = \frac{1}{2} \sum_{i=1}^c P_i \sum_{j=1}^c P_j \frac{1}{n_i n_j} \sum_{k=1}^{n_i} \sum_{l=1}^{n_j} \delta(x_k^{(i)}, x_l^{(j)})$$

其中， $x_k^{(i)} \in \omega_i, k=1, \dots, n_i$

$x_l^{(j)} \in \omega_j, l=1, \dots, n_j$

P_i, P_j 为类 ω_i, ω_j 的类概率

$\delta(x_k, x_l)$ 为类 ω_i 中样本 x_k 与类 ω_j 中样本 x_l 的距离

度量

通常采用欧氏距离：

$$\delta(x_k, x_l) = (x_k - x_l)^T (x_k - x_l)$$

J_D 称为各类之间的平均平方距离

定义：

类均值向量

$$m_i = \frac{1}{n_i} \sum_{k=1}^{n_i} x_k^{(i)}$$

总均值向量

$$m = \sum_{i=1}^c P_i m_i$$

类间离散度矩阵 S_b 的估计：

$$\tilde{S}_b = \sum_{i=1}^c P_i (m_i - m)(m_i - m)^T$$

类内离散度矩阵 S_w 的估计：

$$\tilde{S}_w = \sum_{i=1}^c P_i \frac{1}{n_i} \sum_{k=1}^{n_i} (x_k^{(i)} - m_i)(x_k^{(i)} - m_i)^T = \sum_{i=1}^c \sum_{k=1}^{n_i} P_i (x_k^{(i)} - m_i)(x_k^{(i)} - m_i)^T$$

Σ_i ：类协方差矩阵

则

$$J_D = \text{tr}(\tilde{S}_w + \tilde{S}_b)$$

4. 基于类内类间距离的可分性判据

$$\tilde{S}_w = \sum_{i=1}^c P_i \frac{1}{n_i} \sum_{k=1}^{n_i} (x_k^{(i)} - m_i)(x_k^{(i)} - m_i)^T = \sum_{i=1}^c \frac{1}{n_i} \sum_{k=1}^{n_i} (x_k^{(i)} - m_i)(x_k^{(i)} - m_i)^T$$

Σ_i : 类协方差

则

$$J_D = \text{tr}(\tilde{S}_w + \tilde{S}_b)$$

常用的基于类内类间距离的可分性判据：

$$J_1 = \text{tr}(S_w + S_b)$$

$$J_2 = \text{tr}(S_w^{-1} S_b)$$

$$J_3 = \ln \frac{|S_b|}{|S_w|}$$

5. 基于概率分布的可分性判据，基于熵的可分性判据

$$8J_B = J_D = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)$$

基于概率相关性的可分性判据

考查联合分布密度 $p(x, \omega_i) = p(x | \omega_i)P(\omega_i)$

如 x 与 ω_i 独立, $p(x, \omega_i) = p(x)p(\omega_i)$, 即 $p(x) = p(x, \omega_i)/P(\omega_i)$

则 x 不能提供对分类 ω_i 的信息

因此可定义 $p(x)$ 与 $p(x | \omega_i)$ 之间关系的一个函数作

$$J_i = \int g(p(x | \omega_i), p(x), P(\omega_i)) dx$$

称作概率

7.2.3 基于熵的可分性判据

熵：事件不确定性的度量

A 事件的不确定性大（熵大），则对 A 事件

思路：

把各类 ω_i 看作一系列事件

把后验概率 $P(\omega_i | x)$ 看作特征 x 上出现 ω_i 的概率

如从 x 能确定 ω_i ，则对 ω_i 的观察不提供信息

—— 特征 x 有

如从 x 完全不能确定 ω_i ，则对 ω_i 的观察信息

—— 特征 x 无

定义熵函数 $H = J_c[P(\omega_1 | x), \dots, P(\omega_c | x)]$

须满足

①规一化 $J_c\left(\frac{1}{c}, \dots, \frac{1}{c}\right) = 1$

$$0 \leq J_c(P_1, \dots, P_c) \leq J_c\left(\frac{1}{c}, \dots, \frac{1}{c}\right) = 1$$

②对称性 $J_c(P_1, \dots, P_c) = J_c(P_{\pi}, \dots, P_{\pi})$

③确定性 $J_c(1, 0, \dots, 0) = J_c(0, 1, \dots, 0) = \dots = 0$

④扩张性 $J_c(P_1, \dots, P_c) = J_{c+1}(P_1, \dots, P_c, 0)$

⑤连续性 $P(\omega_i | x)$ 的连续函数

⑥分枝性（综合性） 一分为二，则熵增加；二合为

Shannon 熵:

$$H = - \sum_{i=1}^c P(\omega_i | x) \log_2 P(\omega_i | x)$$

平方熵:

$$H = 2 \left[1 - \sum_{i=1}^c P^2(\omega_i | x) \right]$$

熵可分离性判据: $J_e = \int H(x) p(x) dx$

J_e 大, 则重叠性大, 可分性不好,

J_e 小, 则可分性好。

6. 主成分分析 (简答)

目的 出发点是从一组特征中计算出一组按重要性从大到小排列的新特征, 他们是原有特征的线性组合, 并且互相之间是不相关的。

7. K-L 变换的基本原理

函数的级数展开: 将函数用一组 (正交) 基函数展开, 用展开系数表示原函数。

离散 K-L 展开: 把随机向量用一组正交基向量展开, 用展开系数代表原向量。

基向量所张成的空间: 新的特征空间。

展开系数组成的向量: 新特征空间中的样本向量

二、 计算题

设有两类问题, 其先验概率相等, 即 $P(\omega_1) = P(\omega_2) = \frac{1}{2}$, 样本均值向量分别为 $\mu_1 = [4, 2]^T$, $\mu_2 = [-4, -2]^T$, 协方差矩阵分别是 $\Sigma_1 = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ 和 $\Sigma_2 = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}$ 。试利用 K-L 变换把维数从 2 压缩为 1。

1 总体自相关矩阵 R

$$R=E\{XX^T\}=\frac{1}{2}(\mu_1\mu_1^T+\mu_2\mu_2^T)=\begin{bmatrix} 16 & 8 \\ 8 & 4 \end{bmatrix}$$

2 计算 R 的本征值 并选择较大者。 由 $|R-\lambda I|=0$ 得

$$\lambda_1=24, \lambda_2=0$$

3. 根据 $R\mu_1=\lambda_1\mu_1$ 计算 λ_1 对应的特征向量 μ_1 , 归一化后为

$$U=[u]=\begin{bmatrix} 0.7071 \\ 0.7071 \end{bmatrix}$$

4.利用 U 对样本集中的每一个样本进行 K-L 变换

$$X_1^*=U^T X_1=\begin{bmatrix} 0.7071 & 0.7071 \end{bmatrix}\begin{bmatrix} 4 \\ 2 \end{bmatrix}=\begin{bmatrix} 4.2426 \end{bmatrix}$$

$$X_2^*=U^T X_2=\begin{bmatrix} 0.7071 & 0.7071 \end{bmatrix}\begin{bmatrix} -4 \\ -2 \end{bmatrix}=\begin{bmatrix} -4.2426 \end{bmatrix}$$